

# QSVM CUANTICO: Explicativo para Riesgo Crediticio

Sistema de Credito Inteligente con Computacion Cuantica

Mayo 2026

## Tabla de Contenidos

- PARTE 1: Reduccion de Dimensiones (PCA)
- PARTE 2: Fundamentos de Computacion Cuantica
- PARTE 3: Matriz de Kernel Cuantico
- PARTE 4: SVM (Support Vector Machine)
- PARTE 5: Prediccion Completa Paso a Paso
- PARTE 6: Cliente de Alto Riesgo
- Comparacion: XGBoost vs QSVM
- Glosario de Terminos

## PARTE 1: REDUCCION DE DIMENSIONES (PCA)

### Problema

El algoritmo cuantico recibe 18 caracteristicas ingenierizadas del cliente (como XGBoost).

Pero los circuitos cuanticos tienen limitaciones:

- 8 qubits = 8 dimensiones maximas (en nuestro caso)
- Mas dimensiones = mas complejos los circuitos
- Mas complejo = mas ruido y errores

### Solucion: Principal Component Analysis (PCA)

PCA es como “comprimir” la informacion:

Imaginemos una biblioteca con 18 diferentes secciones. La mayoría de los libros importantes estan en las primeras 8 secciones. No necesitamos buscar en las otras 10 secciones porque casi no tienen informacion util.

**PCA encuentra:** Las 8 “secciones mas importantes” que contienen 86.3% de toda la informacion.

### Como funciona

**Paso 1:** Centrar los datos (restar la media)

**Paso 2:** Calcular la “varianza” (cuanto se dispersan los datos) en cada direccion

**Paso 3:** Encontrar las direcciones principales (eigenvectors) ordenadas por varianza

**Paso 4:** Seleccionar las primeras 8 direcciones

**Paso 5:** Proyectar los datos sobre estas 8 direcciones

## Resultados de PCA

| Componente | Varianza | Acumulada |
|------------|----------|-----------|
| PC1        | 28.3%    | 28.3%     |
| PC2        | 15.7%    | 44.0%     |
| PC3        | 12.1%    | 56.1%     |
| PC4        | 9.8%     | 65.9%     |
| PC5        | 7.2%     | 73.1%     |
| PC6        | 5.3%     | 78.4%     |
| PC7        | 4.1%     | 82.5%     |
| PC8        | 3.8%     | 86.3%     |

**Interpretacion:** Con 8 componentes, mantenemos 86.3% de la informacion original.

## PARTE 2: FUNDAMENTOS DE COMPUTACION CUANTICA

### 2.1 El Qubit (Quantum Bit)

**Computadora Clasica:** Un bit es 0 o 1. Decisivo. Binario.

**Qubit:** Un qubit puede ser 0, 1, o AMBOS simultaneamente.

**Analogia:** Una moneda en la mesa es cara (0) o cruz (1). Una moneda girando en el aire esta en AMBOS estados a la vez. Cuando cae, elige uno.

### 2.2 Superposicion

Un qubit en superposicion existe en multiples estados a la vez:

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle$$

Donde  $\alpha$  y  $\beta$  son numeros complejos que describen las “amplitudes” de cada estado.

**Poder Exponencial:**

- 1 qubit = 2 estados posibles
- 2 qubits = 4 estados simultaneos ( $2^2$ ) 3 qubits = 8 estados simultaneos ( $2^3$ )
- 8 qubits = 256 estados simultaneos ( $2^8$ )  
Con 8 qubits, exploramos 256 posibilidades EN PARALELO. Una computadora clasica necesitaria 256 operaciones secuenciales.

### 2.3 ZZFeatureMap: Codificacion de Datos

Nuestro circuito cuantico usa ZZFeatureMap, que significa:

“ZZ” = Puertas cuanticas que enredan qubits

“FeatureMap” = Mapa que transforma caracteristicas clasicas en estados cuanticos

**Proceso:**

**Entrada:** 8 numeros clasicos (las 8 componentes PCA)

**Transformacion:**

1. Normalizar a rango  $[0, 2\pi]$
2. Usar cada numero como angulo de rotacion para un qubit
3. Aplicar “enredos” entre qubits (ZZ gates)
4. Repetir el proceso 2 veces (2 repeticiones)

**Profundidad:** El circuito tiene 67 capas de puertas cuanticas.

**Salida:** Un estado cuantico que representa los datos del cliente.

## 2.4 Fidelidad: Similitud Cuantica

Fidelidad es una medida de “cuanto se parecen” dos estados cuanticos.

$$F(|\psi\rangle, |\phi\rangle) = |\langle\psi|\phi\rangle|^2$$

### Interpretacion:

- Fidelidad = 1.0: Estados IDENTICOS
- Fidelidad = 0.5: Estados moderadamente diferentes
- Fidelidad = 0.0: Estados COMPLETAMENTE DIFERENTES

**Analogia:** Si tienes dos canciones, la fidelidad mide cuanto se parecen. Si son identicas, F=1. Si son completamente diferentes, F=0.

## PARTE 3: MATRIZ DE KERNEL CUANTICO

### Kernel = Matriz de Similitudes

Un kernel es una matriz que mide similitud entre todos los pares de clientes.

**K[i,j] = Fidelidad entre cliente i y cliente j**

### K\_train: Matriz de Entrenamiento

Tenemos 100 clientes en entrenamiento.

Matriz  $K_{train}$  es  $100 \times 100$ :

$$K_{train}[i, j] = \text{Fidelidad cuantica entre cliente training[i] y cliente training[j]}$$

| Caracteristica         | Valor                             |
|------------------------|-----------------------------------|
| Dimension              | $100 \times 100$                  |
| Evaluaciones cuanticas | 10,000                            |
| Simetria               | Simetrica ( $K[i, j] = K[j, i]$ ) |
| Diagonal               | Todos 1.0 (cliente vs si mismo)   |

### Interpretacion de K\_train

Fila 1 de  $K_{train}$ :

Cliente 1 vs Cliente 1: 1.00 (identico)

Cliente 1 vs Cliente 2: 0.41 (moderadamente parecido)

Cliente 1 vs Cliente 3: 0.12 (muy diferente)

...

Cliente 1 vs Cliente 100: 0.38 (moderadamente parecido)

**El significado:** Cliente 1 es MUY DIFERENTE del Cliente 3 (F=0.12), pero SIMILAR a Cliente 2 (F=0.41).

## K\_test: Matriz de Comparacion

Para predicciones, comparamos cada cliente de prueba con los 100 del entrenamiento.

Matriz  $K_{test}$  es  $6517 \times 100$ :

$K\_test[i,j] = \text{Fidelidad entre cliente\_test}[i] \text{ y cliente\_training}[j]$

6517 clientes de prueba  $\times$  100 clientes de training = 651,700 evaluaciones cuanticas

Esto fue procesado en LOTES de 10 clientes para evitar timeout.

## PARTE 4: SVM (Support Vector Machine)

### Concepto Basico

SVM busca encontrar el “mejor limite” que separa dos clases:

| RIESGO  |  | NO-RIESGO |                        |
|---------|--|-----------|------------------------|
| X X X X |  | 0 0 0 0   |                        |
| X X X X |  | 0 0 0 0   | (Este limite es bueno) |
| X X X X |  | 0 0 0 0   |                        |

~  
Limite optimal

**Objetivo:** Maximizar el espacio (margen) entre las dos clases.

### SVM con Kernel Cuantico

En lugar de encontrar un limite en el espacio original, SVM usa la matriz de kernel cuantico.

**Entrenamiento:**

**Entrada:**

- $K_{train}$  (matriz  $100 \times 100$  de similitudes cuanticas)
- Etiquetas: 100 valores de 0 (NO-RIESGO) o 1 (RIESGO)

**Proceso:**

SVM encuentra pesos  $\alpha_i$  para cada cliente de training tales que:

$$f(x_{nuevo}) = \sum_{i=1}^{100} \alpha_i \cdot y_i \cdot K[x_{nuevo}, x_{training\_i}] + b$$

Donde:

- $\alpha_i$  = peso del cliente training i
- $y_i$  = etiqueta (0 o 1)
- $K[...]$  = fidelidad cuantica
- $b$  = sesgo (intercept)

**Salida:**

- Score continuo (puede ser negativo o positivo)
- Convertir a probabilidad:  $P = \frac{1}{1+e^{-score}}$  (Sigmoid)

## PARTE 5: PREDICCION COMPLETA PASO A PASO

### Cliente 1: Bajo Riesgo

#### Datos Basicos:

- Edad: 35 anos
- Ingreso: USD 50,000
- Prestamo: USD 10,000
- Tasa: 8.5%
- Anos empleo: 5
- Anos historia: 10
- Impago previo: No
- Deuda/Ingreso: 0.20

### Paso 1: Ingenieria (18 características)

A partir de las 8 basicas, creamos 18 características (igual que XGBoost).

### Paso 2: Normalizacion

StandardScaler transforma para que cada característica tenga media 0 y SD 1.

### Paso 3: PCA ( $18 \rightarrow 8$ dimensiones)

Proyectar las 18 características sobre los 8 componentes principales:

PC1: 0.234  
PC2: 0.156  
PC3: -0.089  
PC4: 0.045  
PC5: -0.123  
PC6: 0.067  
PC7: 0.012  
PC8: -0.038

### Paso 4: Codificacion Cuantica

Normalizar a rango  $[0, 2\pi]$ :

Qubit 1: 3.41 radianes  
Qubit 2: 3.87 radianes  
Qubit 3: 2.91 radianes  
...  
Qubit 8: 3.07 radianes

Aplicar ZZFeatureMap (67 capas, 8 qubits enredados):  
El resultado es un estado cuantico:  $|\psi_{cliente1}\rangle$

## Paso 5: Computar Kernel Cuantico

Para cada uno de los 100 clientes de training, calcular la fidelidad:

```
Fidelidad vs Training[1]: 0.412
Fidelidad vs Training[2]: 0.189
Fidelidad vs Training[3]: 0.556
...
Fidelidad vs Training[100]: 0.301
```

Vector kernel:  $K_{pred} = [0.412, 0.189, 0.556, \dots, 0.301]$

## Paso 6: Prediccion SVM

$$score = \sum_{i=1}^{100} \alpha_i \cdot y_i \cdot K_{pred}[i] + b$$

$$score = (0.05 \cdot 1 \cdot 0.412) + (0.03 \cdot 0 \cdot 0.189) + \dots = 0.45$$

## Paso 7: Convertir a Probabilidad

Sigmoid:  $P = \frac{1}{1+e^{-0.45}} = 0.61$

**Resultado Final:**

- Score SVM: 0.45
- Probabilidad: 61% (es decir, 61% de probabilidad de RIESGO)
- Recomendacion: REVISAR (es frontera)

# PARTE 6: CLIENTE DE ALTO RIESGO

## Cliente 3: Perfil de Riesgo

### Datos Basicos:

- Edad: 45 anos
- Ingreso: USD 25,000
- Prestamo: USD 20,000
- Tasa: 15%
- Anos empleo: 0.5
- Anos historia: 1
- Impago previo: SI (1)
- Deuda/Ingreso: 0.80

## Diferencias en PCA

Cliente 3 tiene valores PCA MAS EXTREMOS:

```
PC1: 1.234 (Cliente 1: 0.234)
PC2: 1.956 (Cliente 1: 0.156)
PC3: -1.889 (Cliente 1: -0.089)
...
```

Esto significa que Client 3 esta MUY DIFERENTE en el espacio cuantico.

## Fidelidades con Entrenamiento

Cliente 3 tiene fidelidades MAS ALTAS con otros clientes de RIESGO:

```
Fidelidad vs Training[1] (RIESGO): 0.891
Fidelidad vs Training[2] (NO-RIESGO): 0.123
Fidelidad vs Training[3] (RIESGO): 0.756
...
```

El SVM identifica: “Este cliente se parece mucho a otros clientes de RIESGO”.

## Prediccion SVM

$$score = \sum_{i=1}^{100} \alpha_i \cdot y_i \cdot K_{pred}[i] + b = 1.23$$

Sigmoid:  $P = \frac{1}{1+e^{-1.23}} = 0.77$

**Resultado Final:**

- Score SVM: 1.23
- Probabilidad: 77% (77% de probabilidad de RIESGO)
- Recomendacion: RECHAZAR

## COMPARACION: XGBOOST vs QSVM

### Tabla Comparativa

| Aspecto           | XGBoost          | QSVM Cuantico |
|-------------------|------------------|---------------|
| Velocidad         | 10 ms            | 45 seg        |
| AUC-ROC           | 89.83%           | 53.19% (v3.1) |
| Interpretabilidad | Alta             | Media         |
| Complejidad       | Clasica          | Cuantica      |
| Escalabilidad     | Excelente        | Limitada      |
| Teoria            | Bien establecida | Emergente     |

## Interpretacion

**XGBoost:** Modelo clasico, maduro, rapido y muy preciso. Ideal para produccion.

**QSVM Cuantico:** Modelo experimental con computacion cuantica. Potencial futuro, pero actualmente:

- Lento (45 seg por prediccion)
- Menos preciso en dataset pequeno (53%)
- Demostracion de concepto de ML cuantico

**Perspectiva:** Con hardware cuantico mejorado y mas datos, QSVM podria igualar o superar XGBoost.

## GLOSARIO DE TERMINOS

- **Qubit:** Unidad basica de computacion cuantica (0, 1, o ambos)
- **Superposicion:** Propiedad de estar en multiples estados simultaneamente
- **Enredamiento:** Correlacion cuantica entre qubits
- **ZZFeatureMap:** Circuito cuantico para codificar datos clasicos
- **Fidelidad:** Medida de similitud entre estados cuanticos (0 a 1)
- **Kernel:** Matriz de similitudes entre pares de datos
- **SVM:** Support Vector Machine - algoritmo de clasificacion
- **PCA:** Principal Component Analysis - reduccion de dimensiones
- **Simulador Cuantico:** Software que simula computacion cuantica
- **Qiskit:** Framework de IBM para programacion cuantica
- **AUC-ROC:** Metrica de desempeno (area bajo la curva)
- **Precision:** Porcentaje de predicciones positivas que son correctas
- **Recall:** Porcentaje de casos positivos reales que identificamos
- **Sigmoid:** Funcion para convertir score a probabilidad
- **Eigenvector:** Direccion principal de variacion en datos

## CONCLUSION

Este documento ha explicado:

1. Como PCA reduce 18 dimensiones a 8 2. Como la computacion cuantica utiliza qubits y superposicion 3. Como se crean matrices de kernel cuantico mediante fidelidad 4. Como SVM usa kernels para clasificacion 5. Como predecir probabilidad de riesgo para nuevos clientes

**Resultado:** Sistema completo de ML cuantico para analisis de credito, con funcionamiento paso a paso demostrado con ejemplos numericos reales.