

XGBoost para Análisis de Riesgo Crediticio

Guía Explicativa Paso a Paso

Material Educativo - Departamento de Riesgo

May 20, 2026

Abstract

Este documento explica de manera clara y accesible cómo funciona el algoritmo XGBoost (Extreme Gradient Boosting) en el contexto del análisis de riesgo crediticio. Se incluyen ejemplos prácticos con datos reales, explicaciones teóricas simplificadas y flujos de datos completos para que cualquier persona pueda entender cómo el modelo toma decisiones sobre quién es un riesgo de impago.

Contents

1	Introducción: ¿Qué es XGBoost?	2
1.1	La Idea Principal	2
2	Conceptos Fundamentales	2
2.1	Árbol de Decisión: El Bloque Básico	2
2.2	El Truco de XGBoost: Muchos Árboles Débiles	2
3	Flujo de Datos: Ejemplo Paso a Paso	3
3.1	Datos de Entrada	3
3.2	Paso 1: Normalización (Poner todo en la misma escala)	3
3.3	Paso 2: Ingeniería de Características (Crear nuevas columnas inteligentes)	3
3.4	Paso 3: Entrenamiento (Ajustar los Árboles)	4
3.5	Paso 4: Predicción para el Cliente 1	4
4	Ejemplo Numérico Completo	5
4.1	Cliente 3: El Caso de Alto Riesgo	5
4.1.1	Cálculos de Características	5
4.1.2	Votación de los Árboles	5
4.1.3	Predicción Final	5
5	Métricas de Desempeño	6
5.1	¿Qué Tan Bueno es Nuestro Modelo XGBoost?	6
6	Umbral Óptimo: El Punto de Corte	6
6.1	¿Por Qué 11.6%?	6
7	Ventajas del Modelo XGBoost	6
7.1	¿Por Qué Usamos XGBoost en Lugar de Otros Métodos?	6
8	Resumen del Flujo Completo	7
9	Conclusión	7
A	Glosario de Términos	7

1 Introducción: ¿Qué es XGBoost?

XGBoost es un algoritmo de **aprendizaje automático** diseñado para hacer predicciones precisas. En nuestro caso, lo usamos para predecir quién es **riesgo de no pagar** un crédito.

1.1 La Idea Principal

Imagine que usted es un experto en análisis de crédito con 30 años de experiencia. Ahora imagine que su colega le pregunta:

“¿Esta persona pagará su crédito o no?”

Usted miraría varios factores:

- **Edad:** ¿Es joven o adulto? (experiencia de vida)
- **Ingreso:** ¿Tiene estabilidad financiera?
- **Monto del préstamo:** ¿Es proporcional a su ingreso?
- **Tasa de interés:** ¿Puede pagar los intereses?
- **Historial de crédito:** ¿Ha pagado antes?
- **Historial de impagos:** ¿Ha fallado en pagos anteriores?

XGBoost hace exactamente esto: **combina múltiples factores para tomar una decisión.**

2 Conceptos Fundamentales

2.1 Árbol de Decisión: El Bloque Básico

XGBoost está construido sobre **árboles de decisión**. Un árbol es simple: es una serie de preguntas que conducen a una respuesta.

Ejemplo visual de un árbol simple:

[Estructura: Ingreso > 40k? – – > Edad > 30? – – > Decisiones finales]

2.2 El Truco de XGBoost: Muchos Árboles Débiles

En lugar de crear UN árbol muy complejo (que podría cometer errores), XGBoost crea **200 árboles pequeños** que **votan juntos**.

Analogía:

¿A quién le cree más?

- ¿A UN experto que está 70% seguro?
- ¿O a 10 expertos que CADA UNO está 60% seguro?

Respuesta: A los 10 expertos. XGBoost usa esta idea: **200 pequeños árboles votan y deciden juntos.**

3 Flujo de Datos: Ejemplo Paso a Paso

3.1 Datos de Entrada

Tomemos 5 clientes reales de nuestro dataset:

ID	Edad	Ingreso	Monto	Tasa	Emp. Años	Hist. Crédito	Impago Anterior
1	35	50,000	10,000	8.5%	5	10	NO
2	28	35,000	15,000	12.5%	1	3	SÍ
3	45	25,000	20,000	15%	0.5	1	SÍ
4	55	80,000	8,000	6%	20	25	NO
5	32	42,000	12,000	9%	3	7	NO

Table 1: Ejemplo de clientes para análisis

Objetivo: Para cada cliente, predecir si será **Riesgo (1)** o **No Riesgo (0)**.

3.2 Paso 1: Normalización (Poner todo en la misma escala)

Los datos vienen en diferentes escalas:

- Edad: 20-70 años
- Ingreso: \$10,000 - \$200,000
- Tasa de interés: 3% - 20%

XGBoost necesita que TODO esté en la misma escala. Usamos **StandardScaler**:

$$x_{\text{normalizado}} = \frac{x - \mu}{\sigma}$$

Donde:

- x = valor original
- μ = promedio de todos los valores
- σ = desviación estándar

Ejemplo con Edad del Cliente 1:

Supongamos que todas las edades tienen promedio $\mu = 40$ y desviación $\sigma = 10$:

$$\text{Edad normalizada} = \frac{35 - 40}{10} = \frac{-5}{10} = -0.5$$

Después de normalizar, **todos los datos están entre -3 y 3 aproximadamente**.

3.3 Paso 2: Ingeniería de Características (Crear nuevas columnas inteligentes)

XGBoost trabaja mejor si le damos **características inteligentes**. No solo los datos crudos, sino combinaciones que tengan sentido:

Nombre	Fórmula	Interpretación
Deuda/Ingreso	$\frac{\text{Monto}}{\text{Ingreso}}$	¿Cuánto pide vs. cuánto gana?
Riesgo Interés	Tasa^2	Penaliza tasas altas más
Interacción Préstamo-Ingreso	$\frac{\text{Monto}}{\text{Ingreso}+1}$	Proporción normalizada
Estabilidad Empleo	$\log(\text{Años} + 1)$	Experiencia laboral
Proporción Historial	$\frac{\text{Hist. Crédito}}{\text{Edad}+1}$	Historial relativo a edad

Table 2: Nuevas características creadas para mejorar predicción

Ejemplo: Cliente 1

$$\text{Deuda/Ingreso} = \frac{10,000}{50,000} = 0.20 \quad (20\% \text{ de su ingreso})$$

$$\text{Riesgo Interés} = 8.5^2 = 72.25$$

$$\text{Est. Empleo} = \log(5 + 1) = \log(6) \approx 1.79$$

3.4 Paso 3: Entrenamiento (Ajustar los Árboles)

XGBoost crea 200 árboles pequeños. Cada árbol aprende a partir de los **errores del árbol anterior**.

Concepto clave: Boosting (Impulsión)

Imagine que está enseñando a un estudiante:

1. Primer árbol: Intenta predecir. Comete errores.
2. Segundo árbol: Se enfoca en los clientes que el primero predijo mal.
3. Tercer árbol: Se enfoca en los errores restantes.
4. ... (esto se repite 200 veces)

Cada árbol nuevo **“corrige”** a los anteriores.

3.5 Paso 4: Predicción para el Cliente 1

Una vez entrenado, el modelo hace predicciones:

1. **Árbol 1** vota: “Este cliente tiene 60% probabilidad de NO impago”
2. **Árbol 2** vota: “Basándome en su estabilidad laboral, 40% probabilidad de NO impago”
3. **Árbol 3** vota: “Basándome en su historial, 35% probabilidad”
4. ... (200 votos totales)

Predicción Final (Promedio de todos los votos):

$$\text{Probabilidad de Impago} = \frac{60\% + 40\% + 35\% + \dots}{200} \approx 15\%$$

Decisión:

- Si probabilidad $> 11.6\%$ (umbral óptimo) $\rightarrow$ **RIESGO**
- Si probabilidad $\leq 11.6\%$ $\rightarrow$ **NO RIESGO**

Para el Cliente 1: $15\% > 11.6\% \rightarrow$ **Predicción: RIESGO**

4 Ejemplo Numérico Completo

4.1 Cliente 3: El Caso de Alto Riesgo

Característica	Valor
Edad	45 años
Ingreso	\$25,000
Monto del Préstamo	\$20,000
Tasa de Interés	15%
Años de Empleo	0.5
Años de Historial	1
Impago Anterior	SÍ

Table 3: Datos del Cliente 3

4.1.1 Cálculos de Características

$$\text{Deuda/Ingreso} = \frac{20,000}{25,000} = 0.80 \quad (80\% \text{ de su ingreso} - \text{RIESGO ALTO!})$$

$$\text{Riesgo Interés} = 15^2 = 225 \quad (\text{Tasa muy alta})$$

$$\text{Est. Empleo} = \log(0.5 + 1) = \log(1.5) \approx 0.41 \quad (\text{Muy nuevo en el trabajo})$$

$$\text{Proporción Historial} = \frac{1}{45 + 1} = 0.022 \quad (\text{Muy poco historial})$$

4.1.2 Votación de los Árboles

Árbol	Voto	Razón
1	85%	Deuda/Ingreso muy alta (0.80)
2	78%	Tasa de interés muy alta (15%)
3	72%	Poco tiempo en el empleo (0.5 años)
4	88%	Impago anterior + historial corto
5	81%	Edad 45 con muy poco historial
⋮	⋮	⋮
200	76%	Múltiples factores de riesgo

Table 4: Ejemplos de votos de algunos árboles

4.1.3 Predicción Final

$$\text{Probabilidad Promedio} = \frac{85\% + 78\% + 72\% + 88\% + 81\% + \dots + 76\%}{200} \approx 80\%$$

Comparación con umbral:

$$80\% > 11.6\% \Rightarrow \textbf{PREDICCIÓN: RIESGO ALTO}$$

Explicación para el banco:

Este cliente presenta múltiples señales de alerta:

- Pide un monto (20k) equivalente al 80% de su ingreso anual
- Tasa de interés muy alta (15%), lo que sugiere que es cliente de alto riesgo
- Acaba de empezar el trabajo (0.5 años) - inestable
- Tiene historial de impagos
- **Recomendación: RECHAZAR crédito o cobrar tasa más alta**

5 Métricas de Desempeño

5.1 ¿Qué Tan Bueno es Nuestro Modelo XGBoost?

Métrica	Valor	Significado
Precisión	82.4%	De 100 que predice que IMPAGARÁ, 82 realmente impagan
Recall	65.2%	De todos los que realmente IMPAGAN, detectamos 65 de cada 100
F1-Score	0.73	Balance entre Precisión y Recall (escala 0-1)
AUC-ROC	0.8983	Probabilidad de que el modelo diferencie riesgos vs no-riesgos: 89.83%

Table 5: Desempeño del Modelo XGBoost en conjunto de prueba

Interpretación:

- El modelo es **bastante confiable**
- De cada 100 clientes de riesgo real, detecta 65
- La tasa de falsos positivos es aceptable para el banco

6 Umbral Óptimo: El Punto de Corte

6.1 ¿Por Qué 11.6%?

XGBoost da una probabilidad (0-100%). Pero ¿cuándo decimos “RIESGO”? ¿En 50%? ¿En 20%?

Análisis de Costo-Beneficio:

Escenario	Costo	Valor Recuperado
Rechazo Correcto (evitar impago)	\$0	\$30,000
Aceptación Correcta (cliente paga)	\$0	\$5,000
Rechazo Incorrecto (rechazamos buen cliente)	\$800	\$0
Aceptación Incorrecta (cliente impaga)	\$30,000	\$0

Table 6: Matriz de Costo del Banco

Con estos costos, el banco determinó que el **umbral óptimo es 11.6%**:

- Si probabilidad $\geq 11.6\%$ → Rechazar (costo de rechazo incorrecto: \$800)
- Si probabilidad $< 11.6\%$ → Aceptar (riesgo de impago: \$30,000)

7 Ventajas del Modelo XGBoost

7.1 ¿Por Qué Usamos XGBoost en Lugar de Otros Métodos?

1. **Precisión:** 89.83% AUC-ROC (muy preciso)
2. **Maneja Datos Complejos:** Puede capturar relaciones no-lineales entre variables
3. **Rápido:** Predicciones en milisegundos
4. **Robusto:** Funciona bien incluso con datos imperfectos
5. **Escalable:** Puede procesar millones de clientes
6. **Interpretable:** Podemos explicar por qué rechaza o acepta

8 Resumen del Flujo Completo

[Flujo: Datos Cliente -> Normalizar -> Ingeniería Características -> 200 Árboles -> Promedio Votos -> Umbral 11.6% -> Predicción]

9 Conclusión

XGBoost es un método poderoso que:

1. Toma **múltiples factores** de un cliente
2. Los **transforma inteligentemente** en características
3. Los **pasa por 200 árboles** que votan
4. **Combina los votos** para una predicción
5. **Compara con un umbral óptimo** para tomar la decisión final

Resultado final: Un sistema **confiable al 89.83%** para identificar clientes de riesgo, permitiendo al banco:

- Reducir pérdidas por impagos
 - Maximizar utilidades en colocaciones seguras
 - Tomar decisiones rápidas y consistentes
-

A Glosario de Términos

Árbol de Decisión: Modelo que hace predicciones preguntando preguntas sucesivas

Boosting: Técnica donde múltiples modelos débiles se combinan para crear uno fuerte

AUC-ROC: Métrica que mide qué tan bien el modelo diferencia entre riesgos y no-riesgos

Normalización: Poner todos los datos en la misma escala

Ingeniería de Características: Crear nuevas variables que tengan sentido para el problema

Umbral: Punto de corte para tomar una decisión