

# XGBOOST: Explicativo para Riesgo Crediticio

Sistema de Credito Inteligente

Mayo 2026

## Tabla de Contenidos

- Introduccion: Que es XGBoost?
- Conceptos Fundamentales
- Data Flow Completo
- Normalizacion
- Ingenieria de Caracteristicas
- Entrenamiento
- Predicciones
- Metricas
- Umbral Optimo
- Ventajas
- Glosario

## 1. INTRODUCCION: QUE ES XGBOOST?

XGBoost es un algoritmo de machine learning que combina multiples “expertos debiles” para crear una “prediccion fuerte”.

**Analogia:** Imagina 200 analistas de credito, cada uno con una estrategia simple. Si los 200 votan, su decision conjunta es mucho mas confiable que cualquier experto individual.

XGBoost utiliza:

- **Arboles de Decision:** Estructuras simples que hacen preguntas (Si  $X > Y$ , entonces...)
- **Boosting:** Combina 200 arboles pequenos iterativamente
- **Aprendizaje de Errores:** Cada nuevo arbol intenta corregir los errores del anterior

## Resultado

- Velocidad: ~10 milisegundos por prediccion
- Precision: AUC-ROC 89.83%
- F1-Score: 0.73 (Balance precision-recall)

## 2. CONCEPTOS FUNDAMENTALES

### 2.1 Arbol de Decision

Un arbol de decision es una serie de preguntas:

```
[Inicio: Cliente]
|
+-- Es edad > 35?
    |
    +-- Si: Edad_Riesgo = Bajo
    |
    +-- No: Edad_Riesgo = Alto
```

Cada respuesta (Si/No) divide los clientes en grupos mas homogeneos.

### 2.2 Boosting

Boosting significa “empujar hacia arriba”:

**Iteracion 1:** Entrena un arbol con todos los datos.

**Iteracion 2:** Entrena un arbol ENFOCANDOSE en los errores de la iteracion 1.

**Iteracion 3-200:** Cada arbol intenta corregir los errores acumulados.

**Prediccion Final:** Suma ponderada de todos los 200 arboles.

## 3. DATA FLOW COMPLETO

### Paso 1: Entrada

Se reciben 8 caracteristicas basicas del cliente:

1. **age** - Edad del cliente
2. **income** - Ingreso anual (en miles USD)
3. **loan\_amount** - Monto del prestamo (en miles USD)
4. **interest\_rate** - Tasa de interes (%)
5. **employment\_years** - Anos de empleo
6. **credit\_history\_years** - Anos de historial crediticio
7. **prior\_default** - Impago previo? (0 o 1)
8. **debt\_to\_income** - Deuda / Ingreso (ratio)

### Paso 2: Ingenieria de Caracteristicas

A partir de las 8 caracteristicas basicas, se crean 18 nuevas:

| Caracteristica Original | Derivadas (Ejemplos)                          |
|-------------------------|-----------------------------------------------|
| age                     | age_square, age_group_young, age_group_old    |
| income                  | income_per_loan, log_income, income_stability |
| loan_amount             | loan_to_income, loan_per_year                 |
| interest_rate           | rate_risk_premium, rate_volatility            |

**Por que?** Estos ratios y transformaciones capturan relaciones no lineales que los arboles pueden aprender mejor.

### Paso 3: Normalizacion

StandardScaler transforma cada caracteristica para tener:

- Media = 0
- Desviacion estandar = 1

**Formula:**

$$X_{scaled} = \frac{X - \mu}{\sigma}$$

Donde  $\mu$  = media,  $\sigma$  = desviacion estandar.

**Beneficio:** XGBoost converge mas rapido cuando todas las caracteristicas estan en la misma escala.

## 4. ENTRENAMIENTO

### Configuracion

| Parametro           | Valor            |
|---------------------|------------------|
| Numero de Arboles   | 200              |
| Profundidad Maxima  | 6                |
| Tasa de Aprendizaje | 0.1              |
| Regularizacion L2   | 1.0              |
| Balance de Clases   | scale_pos_weight |

### Manejo de Desbalance

En los datos de entrenamiento:

- 20,186 clientes sin impago (NO-RIESGO)
- 14,456 clientes con impago (RIESGO)

Razon:  $\approx 41\%$  de impagos.

XGBoost ajusta automaticamente los pesos para dar mas importancia a los casos raros (impagos).

## 5. PREDICCIONES: EJEMPLO NUMERICO

### Cliente 1: Bajo Riesgo

**Datos Basicos:**

- Edad: 35 anos
- Ingreso: USD 50,000/ano
- Prestamo: USD 10,000
- Tasa: 8.5%
- Anos empleo: 5
- Anos historia crediticia: 10
- Impago previo?: No (0)

- Deuda/Ingreso: 0.20

### **Paso 1: Ingenieria**

- $\text{age\_square} = 1225$
- $\text{income\_per\_loan} = 5.0$
- $\text{loan\_to\_income} = 0.20$
- $\text{rate\_risk} = 8.5 - \text{mean\_rate} = -1.2$

### **Paso 2: Normalizacion**

- $\text{age\_norm} = 0.15$
- $\text{income\_norm} = 0.32$
- $\text{loan\_norm} = -0.45$
- $\text{debt\_to\_income\_norm} = -0.33$

### **Paso 3: XGBoost Prediccion**

200 arboles predicen: “Riesgo = 0.15” (15% probabilidad)

### **Resultado Final:**

- Probabilidad de Impago: 15%
- Recomendacion: APROBAR
- Risk Score: 15/100

## **Cliente 3: Alto Riesgo**

### **Datos Basicos:**

- Edad: 45 anos
- Ingreso: USD 25,000/ano
- Prestamo: USD 20,000
- Tasa: 15%
- Anos empleo: 0.5
- Anos historia crediticia: 1
- Impago previo?: Si (1)
- Deuda/Ingreso: 0.80

### **Normalizacion**

- $\text{debt\_to\_income\_norm} = 2.15$  (MUY ALTO)
- $\text{employment\_years\_norm} = -1.8$  (BAJO)
- $\text{prior\_default} = 1$  (RIESGO)

- interest\_rate\_norm = 1.95 (ALTO)

### XGBoost Prediccion

200 arboles predicen: “Riesgo = 0.78” (78% probabilidad)

### Resultado Final:

- Probabilidad de Impago: 78%
- Recomendacion: RECHAZAR
- Risk Score: 78/100

## 6. METRICAS DE DESEMPENO

En Dataset de Prueba (6,517 clientes)

| Metrica       | Valor           |
|---------------|-----------------|
| AUC-ROC       | 0.8983 (89.83%) |
| Precision     | 0.824 (82.4%)   |
| Recall        | 0.652 (65.2%)   |
| F1-Score      | 0.73            |
| Especificidad | 0.9512          |

### Interpretacion:

- **AUC 89.83%:** El modelo discrimina muy bien entre riesgo y no-riesgo
- **Precision 82.4%:** De los que predecimos como RIESGO, 82.4% realmente son riesgo
- **Recall 65.2%:** De todos los clientes reales de RIESGO, identificamos 65.2%
- **F1 0.73:** Balance bueno entre precision y recall

## 7. UMBRAL OPTIMO: 11.6%

XGBoost predice probabilidades continuas (0-100%). Debemos elegir un umbral:

**Si probabilidad > umbral: RECHAZAR Si probabilidad <= umbral: APROBAR**

### Analisis de Costo-Beneficio

| Umbral         | Costo Impago | Costo Falsa Alarma |
|----------------|--------------|--------------------|
| 5%             | USD 5,000    | USD 50,000         |
| 10%            | USD 15,000   | USD 20,000         |
| 11.6% (OPTIMO) | USD 12,000   | USD 12,000         |
| 15%            | USD 20,000   | USD 5,000          |

En 11.6%:

- Costo de impago no detectado: USD 12,000 (cliente se fue a la quiebra sin nuestra deteccion)
- Costo de falsa alarma: USD 12,000 (cliente rechazado que hubiera pagado)
- Costo total minimizado: USD 24,000

## 8. VENTAJAS DE XGBOOST

1. **Velocidad:** 10 ms por prediccion (RAPIDO)
2. **Precision:** 89.83% AUC (MUY BUENO)
3. **Robustez:** Maneja automaticamente desbalance de clases
4. **Interpretabilidad:** Podemos entender importancia de cada caracteristica
5. **Escalabilidad:** Maneja millones de clientes
6. **Estabilidad:** Resultados predecibles y reproducibles

## 9. RESUMEN

**XGBoost** es un algoritmo que:

1. Toma 8 caracteristicas basicas del cliente 2. Crea 18 caracteristicas derivadas (ratios, transformaciones) 3. Entrena 200 arboles de decision que votan juntos 4. Predice probabilidad de impago con 89.83% de precision 5. Permite establecer umbral optimo (11.6%) para decision APROBAR/RECHAZAR

**Resultado:** Sistema automatizado, rapido y confiable para analisis de credito.

## 10. GLOSARIO

- **Arbol de Decision:** Estructura que hace preguntas Si/No para clasificar
- **Boosting:** Combinar multiples modelos debiles en uno fuerte
- **AUC-ROC:** Area bajo la curva de precision vs recall
- **Precision:** De lo que predecimos positivo, cuanto es realmente positivo?
- **Recall:** De lo positivo real, cuanto logramos predecir?
- **F1-Score:** Promedio armonico de precision y recall
- **Normalizacion:** Transformar datos a misma escala
- **StandardScaler:** Metodo de normalizacion (media 0, SD 1)
- **Desbalance:** Cuando hay mas casos de una clase que otra
- **Umbral:** Punto de corte para decision binaria